

Modelagem espaço-temporal bayesiana utilizando INLA

Uma aplicação na estimação e predição do risco de roubo de
celulares nos municípios de São Paulo

Caio Gomes Alves Pedro Francisco Godoy Bernardinelli
Rafael Ribeiro Santos

3, Jul, 2025



Sumário I

1 Introdução

2 Metodologia

3 INLA

4 Resultados

5 Conclusão

6 Referências

Introdução

Motivação

- Secretaria de Segurança Pública do Estado de São Paulo disponibiliza online os registros de roubos de celulares que geraram boletins de ocorrência;
- Os dados compõem 8 arquivos, um para cada ano entre 2017 e 2024, contendo um BO e suas informações georreferenciadas por linha;
- Uma maneira de determinar o quão perigosa é uma região é por meio da estimação do risco relativo de roubo.

Motivação

- Não queremos, no entanto, um modelo para cada ano, e sim um que incorpore o efeito temporal presente de maneira inerente nos dados;
- Modelagem espaço-temporal é complicada, pois exige a especificação da interação entre processos que são, de maneira independente, complexos;
- O uso de inferência bayesiana é uma forma de acomodar diferentes abordagens que podem ajudar a modelagem.

Metodologia

Conjunto de dados


Problema

Roubos ocorridos em regiões como parques e metrô não possuem latitude/longitude associadas, gerando quantidade considerável de *missing* (aproximadamente 50% em certas regiões).

Solução

Aglomerar as ocorrências por município, e considerar uma estrutura espacial areal.

Matriz de adjacência



Conjunto de dados

Após tratamento das bases, obtivemos a seguinte estrutura:

Município	X2017	X2018	X2019	X2020	X2021
Adamantina	57	43	41	28	37
Campinas	7789	7106	6922	3370	2868
São Paulo	255145	260452	301357	256047	282935
Zacarias	5	4	10	6	0

Medida de incidência

- Uma maneira de indicar o risco de roubo é por meio do **SIR**: *Standardized Incidence Ratio*, dado por:

$$SIR_{it} = \frac{Y_{it}}{E_{it}}$$

- Onde Y_{it} é a contagem de casos (roubos) e E_{it} é a expectativa de casos no município i no ano t , obtida por padronização indireta.

Modelo

- O modelo foi construído para estimar a contagem de roubos a partir da seguinte relação:

$$Y_{it} \sim \text{Pois}(E_{it}\theta_{it})$$
$$\log(\theta_{it}) = X_{it}\beta + u_i + v_i + \phi_t + \gamma_t + \delta_{it}$$

- Onde β é um vetor de parâmetros da regressão, u_i, v_i são efeitos aleatórios espaciais, γ_t, ϕ_t são efeitos aleatórios temporais e δ_{it} é um efeito de interação espaço-temporal.

Efeitos espaciais

- Os efeitos espacialmente correlacionados u_i seguem um modelo Condicional Autorregressivo BYM (Besag, York, and Mollié 1991), dado por:

$$u_i | u_{-i} \sim N \left(\bar{u}_{\nu_i}, \frac{\sigma_u^2}{n_{\nu_i}} \right)$$

- Onde $\bar{u}_{\nu_i} = n_{\nu_i}^{-1} \sum_{j \in \nu_i} u_j$, com ν_i e n_{ν_i} representando o conjunto e a quantidade de vizinhos do município u_i .

Efeitos temporais

- Os efeitos temporalmente correlacionados ϕ_t seguem um modelo *Random Walk* de ordem 1, dado por:

$$\phi_t | \phi_{t-1} \sim N(\phi_{t-1}, \sigma_\phi^2)$$

- Inicialmente foi proposto um modelo Autorregressivo AR(1), porém modelos *Random Walk* possuem estrutura de posto completo, auxiliando a estimação.

Efeitos não-correlacionados

- Os efeitos espaciais e temporais não-correlacionados v_i, γ_t seguem distribuição Normal, com médias 0 e variâncias $\sigma_v^2, \sigma_\gamma^2$:

$$v_i \sim N(0, \sigma_v^2)$$

$$\gamma_t \sim N(0, \sigma_\gamma^2)$$

Interação espaço-temporal

- Knorr-Held propõe 4 tipos de interações espaço-temporais δ_{it} , entre os seguintes efeitos:

Tipo.de.interação	Efeito.espacial	Efeito.temporal
Tipo I	v_i	γ_t
Tipo II	v_i	ϕ_t
Tipo III	u_i	γ_t
Tipo IV	u_i	ϕ_t

Modelagem

- O modelo foi ajustado utilizando o pacote R-INLA, com auxílio dos pacotes `spdep`, `sf` e `SpatialEpi` para tratamento dos dados espaciais e `tidyverse` para manipulação das bases;
- Esse método foi formulado para ajuste de modelos gaussianos latentes, porém nos últimos anos a quantidade de diferentes aplicações foi aumentada;
- A abordagem do INLA envolve o paradigma bayesiano, porém por meio de aproximações numéricas ao invés de algoritmos de amostragem.

INLA

Introdução

- INLA (*Integrated Nested Laplace Approximation*) foi desenvolvido e proposto por (Rue, Martino, and Chopin 2009);
- A ideia central é aproximar as distribuições marginais a posteriori para cada parâmetro, ao invés de encontrar a distribuição conjunta a posteriori;
- Dessa forma, pula-se o passo de obtenção de amostras MCMC (por Amostrador de Gibbs, por exemplo) para estimação dos parâmetros, diminuindo assim o tempo computacional necessário para modelagem.

Estimação das marginais

- Assim, sejam $y \in \mathbb{R}$ o vetor de observações, $x \in \mathbb{R}^n$ um vetor de variáveis latentes e $\theta \in \mathbb{R}^p$ um vetor de hiperparâmetros. Temos pelo Teorema de Bayes que:

$$p(x, \theta | y) \propto p(\theta) p(x | \theta) p(y | x, \theta)$$

- O interesse no INLA é de obter as distribuições marginais, ou seja:

$$p(x_i | y) = \int p(x_i | \theta) p(\theta | y) d\theta \approx \int \tilde{p}(x_i | \theta) \tilde{p}(\theta | y) d\theta$$

$$p(\theta_j | y) = \int p(\theta | y) d\theta_{-j} \approx \int \tilde{p}(\theta | y) d\theta_{-j}$$

Aproximações

- Nesse passo é utilizada a Aproximação de Laplace, que busca aproximar essas distribuições por meio de uma Gaussiana centrada na moda;
- Para isso, a moda a posteriori (θ^*) de $p(\theta|y)$ é obtida maximizando $\log(p(\theta|y))$, usualmente por algum método de Quase-Newton;
- Após isso, algum método de diferenças finitas é usado para estimar o valor negativo do hessiano $\mathbf{H}$.

Aproximações

- Com isso, é possível encontrar a decomposição do valor singular de $\mathbf{H}^{-1}$, dada por $\mathbf{H}^{-1} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}'$;
- Então, é feito o reescalonamento de θ , através de $\theta(z) = \theta^* + \mathbf{V}\mathbf{\Lambda}^{1/2}z$, que facilita a exploração de θ , corrigindo a escala e rotação;
- Finalmente, $\log(p(\theta|y))$ é explorada utilizando a parametrização de (z) .


Exploração de θ

- O principal método para exploração de $\log(p(\theta|y))$ é por meio de um *grid* regular centrado na moda;
- Os pontos são considerados para a integração numérica se o seguinte critério for atendido:


$$|\log(p(\theta(0)|y)) - \log(p(\theta(z)|y))| < \epsilon, \epsilon > 0$$

- Outros métodos otimizam a escolha de pontos no *grid*, principalmente quando o número de hiperparâmetros aumenta.


Exploração de θ




Exploração de θ



Exploração de θ



Exploração de θ



Aproximação

- Com os valores aproximados das distribuições é possível resolver as integrais numericamente, por meio da seguinte soma:

$$\tilde{p}(x_i|y) = \sum_k \tilde{p}(x_i|\theta_k) \tilde{p}(\theta_k|y) \Delta_k$$

- Em que Δ_k é um peso atribuído para cada soma em θ_k .

Resultados

Hiperparâmetros

- Temos os seguintes hiperparâmetros para o modelo ajustado:

$$\sigma_u^{-2} = \tau_u$$

$$\sigma_v^{-2} = \tau_v$$

$$\sigma_\phi^{-2} = \tau_\phi$$

$$\sigma_\gamma^{-2} = \tau_\gamma$$

Hiperparâmetros

- A distribuição a priori para cada hiperparâmetro é uma Log-Gamma, com valores não informativos;
- Considerou-se a Inversa Wishart, mas a recomendação dos autores é para a Log-Gamma como padrão;
- Dependendo da forma da interação espaço-temporal escolhida, ocorre aninhamento nos hiperparâmetros.


Modelagem

- Foram ajustados 4 modelos, um para cada tipo de efeito de interação espaço-temporal δ_{it} ;
- Para a seleção de modelo, escolheu-se o uso do DIC (*Deviance Information Criterion*), bem como a minimização do erro quadrático médio da predição para 2024 utilizando um modelo com os dados até 2023;
- Em ambos os casos, o modelo escolhido foi o que apresentou interação do tipo II.


Distribuição a posteriori dos hiperparâmetros

hyper	mean	sd	mode
Precision for u (iid component)	1746.84	2110.2	247.2
Precision for u (spatial component)	2273.15	2800.2	368.61
Precision for gamma	30.54	15.08	22.17
Precision for phi	23046.12	29214.1	3656.84
Precision for v	13.94	0.54	13.89


Distribuição a posteriori dos hiperparâmetros




Risco relativo a posteriori



Comparação com interação do tipo I



Efeito temporal estimado



Conclusão

INLA

- Apresentou boa modelagem, com tempo computacional muito baixo;
- Acomodou bem tanto a estrutura espacial areal quanto o efeito temporal;
- Permitiu realizar predições de maneira simples e coerentes.

INLA - Limitações

- Para que o método seja bem utilizado, algumas suposições são necessárias:
 - Distribuições unimodais;
 - Pequena quantidade de hiperparâmetros.
- Modificações foram implementadas para acomodar modelos com distribuições que não sejam unimodais, como misturas, modelos de limiar, GAMs e GAMLSS;
- As suposições foram atendidas nesse caso, mas é importante verificá-las antes de usar cada método.

Discussão

- Estimado um crescimento global no risco de roubo para 2025;
- Processo de “migração” do risco do interior em 2017 para o litoral, em 2025;
- Forte influência da pandemia no risco durante os anos de 2020 - 2022.

Trabalhos futuros

- Trabalhar com inclusão de covariáveis a nível municipal e anual;
- Ajustes usando dados com resolução maior (evitar desalinhamento dos dados areais);
- Publicação dos resultados obtidos.

Referências

Referências

- Besag, Julian, Jeremy York, and Annie Mollié. 1991. “Bayesian Image Restoration, with Two Applications in Spatial Statistics.” *Annals of the Institute of Statistical Mathematics* 43 (1): 1–20. <https://doi.org/10.1007/BF00116466>.
- Knorr-Held, Leonhard. 2000. “Bayesian Modelling of Inseparable Space-time Variation in Disease Risk.” *Statistics in Medicine* 19 (17-18): 2555–67. [https://doi.org/10.1002/1097-0258\(20000915/30\)19:17/18%3C2555::AID-SIM587%3E3.0.CO;2-#](https://doi.org/10.1002/1097-0258(20000915/30)19:17/18%3C2555::AID-SIM587%3E3.0.CO;2-#).
- Rue, Håvard, Sara Martino, and Nicolas Chopin. 2009. “Approximate Bayesian Inference for Latent Gaussian Models by Using Integrated Nested Laplace Approximations.” *Journal of the Royal Statistical Society Series B: Statistical*