Resultados preliminares

Caio Gomes Alves *Instituto de Matemática, Estatística e Computação Científica - UNICAMP*

Mudanças na modelagem

Parametrização

Para que a comparação entre o método proposto e o já existente pelo pacote `ETAS` seja mais direta, a parametrização do modelo foi ajustada para seguir a de Jalilian (2019), como segue:

$$\lambda_\theta(t,x,y|\mathcal{H}_t) = \mu(x,y) + \sum_{i:t_i<t} \kappa_{A,\alpha}(m_i) g_{c,p}(t-t_i) f_{D,\gamma,q}(x-x_i, y-y_i, m_i) \tag{1}$$

Onde:

$$\kappa_{A,\alpha}(m_i) = A\exp\left(\alpha(m_i - m_0)\right)$$

$$g_{c,p}(t-t_i) = \frac{p-1}{c}\left(1+\frac{t-t_i}{c}\right)^{-p}$$

$$f_{D,\gamma,q}(x-x_i, y-y_i; m_i) = \frac{q-1}{\pi D\exp\left(\gamma(m_i-m_0)\right)}\left(1+\frac{(x-x_i)^2+(y-y_i)^2}{D\exp\left(\gamma(m_i-m_0)\right)}\right)$$

Assim, tanto a produtividade $\kappa(m_i)$ quanto a distribuição da Lei de Omori Modificada $g(t-t_i)$ seguem as mesmas parametrizações anteriores, mudando a distribuição espacial dos *aftershocks* para uma radialmente simétrica e isotrópica $f(x-x_i, y-y_i; m_i)$, como proposta por Ogata (1988). O *background rate* $\mu(x,y)$ é estimado de maneira semi-paramétrica, por um *kernel* adaptativo e condicional às probabilidades de ser pai/filho.

Uma diferença para o que é feito pelo pacote `ETAS` é que o mesmo considera a distribuição das magnitudes (marcas) como seguindo uma distribuição exponencial com parâmetro β a ser estimada. No método proposto, é considerada a Lei de Gutenberg-Richter e a modificação de Utsu, como segue:

$$\log_{10}(N) = a - b\times m$$
$$\hat{b} = \frac{\log_{10}(e)}{(\bar{m}-m_0)}$$

Onde a é uma constante não que não precisa ser estimada, $\bar{m}$ é a média das magnitudes maiores do que m_0 no catálogo, enquanto que $\hat{b}$ é estimado de maneira separada dos demais parâmetros do modelo (devido à independência das marcas que é suposição do modelo).

A log-verossimilhança do modelo foi implementada pela função `log_lik_etas` e depende das probabilidades de ser pai/filho, estimadas no passo E. O gradiente da log-verossimilhança também foi implementado e atualizado para incluir os novos parâmetros, por meio da função `gradiente_etas_completo`. Ambos são usados no passo M, por meio da função `optim`, utilizando o método L-BFGS-B que impõe restrições de caixa para que não ocorram escapes do espaço paramétrico.

Otimização do cálculo de probabilidades

O cálculo principal do passo E do algoritmo EM implementado se dá por meio das seguintes contas:

$$p_{i,j} = \begin{cases} \frac{\kappa(m_i) g(t_j - t_i) f(x_j - x_i, y_j - y_i; m_i)}{\lambda_\theta(t_j, x_j, y_j | \mathcal{H}_{t_j})}, & t_j > t_i \\ 0 & t_j \leq t_i \end{cases}$$

$$p_j = \sum_{i:t_i<t_j} p_{i,j}, \quad j = 1, \ldots, N$$

Que calcula a probabilidade $p_{i,j}$ de um evento j ser filho de um evento i, e a probabilidade p_j de um evento ser filho independentemente de quem seja o pai. Anteriormente, a função implementada (`calcular_probabilidades`) fazia a chamada de funções externas repetidamente, sendo que a mesma podia ser feita apenas uma vez. A nova implementação está como segue:

```
# Calcula as probabilidades p_ij (passo E do EM):
calcular_probabilidades <- function(df_eventos, theta, M0, raster_mu,
                                    x_grid, y_grid, num_cores = 1) {
    n <- nrow(df_eventos)
    # Valores do background rate (mu) para todos os eventos:
    mu_vals <- func_nu(raster_mu, df_eventos, x_grid, y_grid)$lyr.1
    # Cálculo paralelizado pelo mclapply:
    probabilidades <- mclapply(1:n, function(j) {
        # Primeiro evento tem probabilidade 0 de ser descendente:
        if (j == 1) return(numeric(0))
        # Atualiza o índice de cada evento:
        i_indices <- 1:(j - 1)
        numeradores <- kappa_func(df_eventos$mag[i_indices], M0, theta["A"], theta["alpha"]) *
            g_func(df_eventos$time[j] - df_eventos$time[i_indices], theta["c"], theta["p"]) *
            f_spatial(
            (df_eventos$x[j] - df_eventos$x[i_indices])^2 +
            (df_eventos$y[j] - df_eventos$y[i_indices])^2,
            df_eventos$mag[i_indices], M0, theta["D"], theta["q"], theta["gamma"]
            )
        denom <- mu_vals[j] + sum(numeradores)
        return(numeradores / denom)
    }, mc.cores = num_cores)
    prob_total <- vapply(probabilidades, sum, numeric(1))
    # Retorna as probabilidades individuais e totais de cada evento:
    list(probabilidades = probabilidades, prob_total = prob_total)
}
```

Com a nova implementação, o tempo necessário para calcular o passo E foi reduzido drasticamente, acelerando assim o processo de modelagem como um todo.

Análise de Resíduos

Podemos verificar a qualidade do ajuste realizado por meio dos resíduos do modelo. Para isso, avaliam-se duas dimensões: temporal e espacial. A partir de agora, todas as análises serão feitas para o catálogo do Irã, usado por Jalilian no artigo do pacote `etas`.

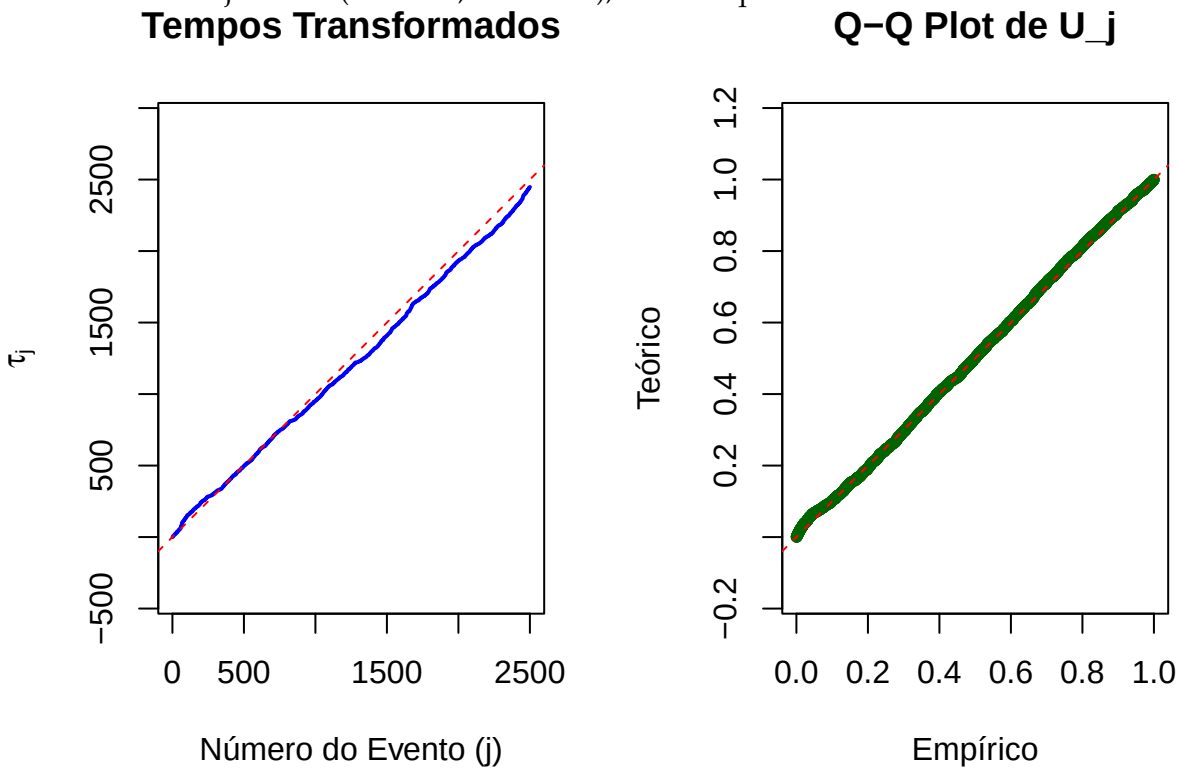
Temporais

Para a parte temporal, podemos usar a intensidade condicional temporal que é dada pela integral da intensidade completa no espaço, que é dada por:

$$\int_0^{\Delta t} g(s)\, ds = 1 - \left(\frac{c}{\Delta t + c}\right)^{p-1} \tag{2}$$

Podemos assim calcular τ (a intensidade acumulada) para qualquer tempo, por meio da função `calcular_tau`. Sejam os tempos de dois eventos seguidos t_i e t_j, então $\tau_{i,j} = \int_{t_i}^{t_j} g(s)\, ds = 1 - \left(\frac{c}{(t_j - t_i)+c}\right)^{p-1}$. Se o modelo estiver bem ajustado (no sentido dos parâmetros temporais c e p), então $U_{i,j} = 1 - \exp(-\tau_{i,j})$, com $U \sim \text{Unif}(0,1)$.

Com os valores ajustados (0.160274, 1.2817266), teremos que:

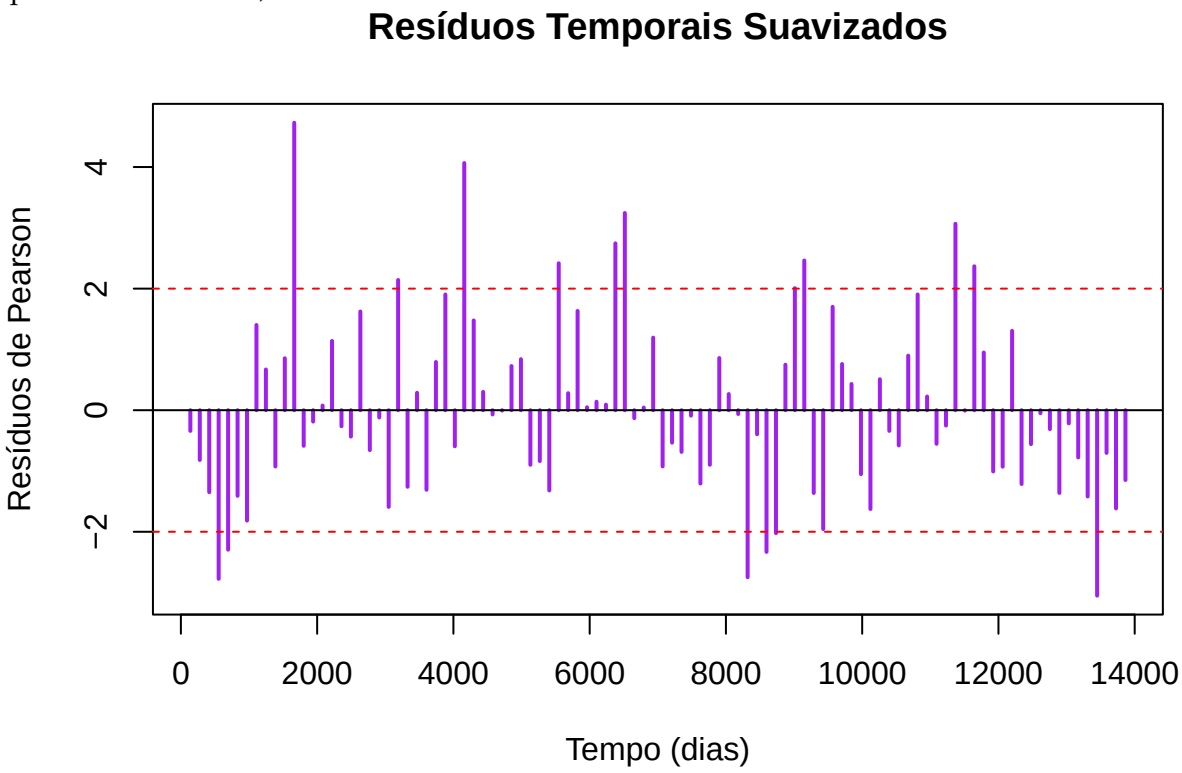


Podemos ver que os tempos transformados e o Q-Q Plot apresentam ajustes ótimos, podendo ser feito o teste de Kolmogorov-Smirnov para testar se U_j é uniformemente distribuído:

```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  U_j_iran
## D = 0.020431, p-value = 0.2476
```

```
## alternative hypothesis: two-sided
```

Além disso, podemos fazer uma análise de resíduos por *bins*. Isso é feito por meio da diferença entre a quantidade de terrremotos ocorridos em cada intervalo e a quantidade esperada dada pelo modelo (calculada da mesma forma que anteriormente, porém com os limites sendo os de cada intervalo). Após isso, para serem normalizados, divide-se pela raiz quadrada da quantidade esperada e, caso o modelo esteja bem ajustado, não deve pode aparentar nenhuma forma de padrão temporal. Para 100 *bins*, teremos:

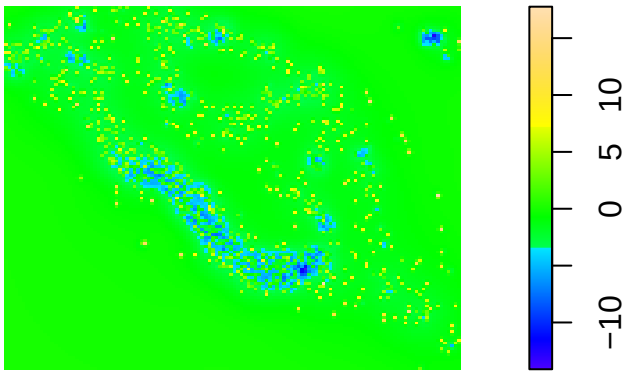


Espaciais

A mesma ideia é feita para a dimensão espacial, sendo avaliada a diferença entre a quantidade de terremotos ocorridos em um *pixel* no *grid* da região de interesse, e a quantidade esperada dada pelo modelo. Para isso, é necessário criar a densidade espacial esperada gerada pelo *background rate* (que depende da probabilidade de ser pai/filho estimada pelo passo E do EM), que é dependente somente dos pais.

Após isso, todos os eventos contribuem para a intensidade condicional, usando os parâmetros estimados pelo modelo. Com isso, temos que a quantidade esperada pelo modelo será dada pela soma da contribuição do *background* com a intensidade condicional de cada evento.

Caso o modelo esteja bem ajustado, não deve ser possível identificar nenhuma forma de padrão espacialmente distribuído. Os resultados são os seguintes:



Há regiões em que ocorreram eventos mas com pouca quantidade esperada (dada pelos pontos amarelos), enquanto que há uma região com valores esperados altos, mas poucos eventos ocorridos. Isso provavelmente ocorre pelo tamanho do *grid* (feito em 128 por 128 *pixels*), que caso fosse menor não teria uma região com subestimação.

Erro-padrão dos estimadores

Via Hessiana

Como o gradiente da função de log-verossimilhança é dado para o `optim()`, ao final da otimização o valor da hessiana pode ser extraído, e pelo fato da verossimilhança ser fatorável, o resultado é uma matriz hessiana $\hat{H}_\theta$ bloco-diagonal, com parâmetros que não tem correlação tendo valor 0.

Assim, o erro-padrão de cada estimativa pode ser calculado de forma:

$$EP(\theta) = \sqrt{\text{diag}\left(\hat{H}_\theta^{-1}\right)} \tag{3}$$

Para o catálogo do Irã (usado para título de comparação entre o método proposto e o de Jalilian (2019)), temos que a hessiana ao final do último passo é:

```
##                A     alpha         c         p           D          q      gamma
## A      18752.891 1535.7208     0.000     0.000       0.000     0.0000    0.00000
## alpha   1535.721  240.6471     0.000     0.000       0.000     0.0000    0.00000
## c          0.000    0.0000  3802.513 -4764.767       0.000     0.0000    0.00000
## p          0.000    0.0000 -4764.767 12331.984       0.000     0.0000    0.00000
## D          0.000    0.0000     0.000     0.000 1054134.952 -25391.8841 6864.20288
## q          0.000    0.0000     0.000     0.000  -25391.884    785.6389 -165.56879
## gamma      0.000    0.0000     0.000     0.000    6864.203   -165.5688   86.68414
```

Vale notar que a mesma é realmente bloco-diagonal, como esperado pela forma da verossimilhança. O erro-padrão estimado para cada parâmetro, junto com o valor estimado, será:

```
##                        A      alpha         c         p           D         q      gamma
## Estimativas   0.22846076 1.94867209 0.1602740 1.28172658 0.018228922 2.11616976 0.04525585
## Erro-Padrão   0.01056886 0.09329789 0.0225789 0.01253781 0.002298591 0.07580962 0.15432858
```

Os valores usados como chute inicial foram $\theta = (A = 0.23, \alpha = 2.8, c = 0.022, p = 1.12, D = 0.012, q = 2.3, \gamma = 0.03)$, que são os mesmos usados no *paper* Jalilian (2019). Para título de comparação, os valores das estimativas e erros-padrões associados quando usada a função `etas` são:

```
## ETAS model: fitted using iterative stochastic declustering method
## converged after 5 iterations: elapsed execution time 8.78 minutes
##
## ML estimates of model parameters:
##             beta     mu      A      c  alpha      p      D      q     gamma
## Estimate 5.8043 0.5134 0.1883 0.0595 2.3269 1.1692 0.0226 2.6492         0
## StdErr   0.0297 0.0098 0.0371 0.0876 0.0333 0.0083 0.0824 0.0372 164193441
##
## Declustering probabilities:
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  0.0000  0.1069  0.9094  0.6414  0.9796  1.0000
##
## log-likelihood:  -7146.193   AIC:  14308.39
```

Podemos ver que os valores estimados por ambos os métodos foram (relativamente) próximos, mas com erros-padrões muito diferentes.

Via bootstrap

Vale citar que a estimativa do erro-padrão dos estimadores obtida por meio da hessiana do passo M subestima a verdadeira variabilidade, como demonstrada por Louis (1982). Isso ocorre pois a quantidade de observações efetiva é menor do que a usada para maximizar a função objetivo, que usa a verossimilhança completa ao invés da parcial.

Uma forma de "prevenir" esse problema seria simular várias amostras *bootstrap* de catálogos usando os valores estimados pelo modelo (tanto de *background rate* quanto de $\hat{\theta}$), reajustar o modelo para cada uma das amostras, e utilizar os resultados para calcular o erro-padrão *bootstrap* (além de outras quantidades, como viés e intervalos de confiança *bootstrap*).

Por isso, um estudo de simulação foi feito, com 100 amostras *bootstrap* geradas a partir das estimativas finais de $\hat{\mu}(x, y)$ e $\hat{\theta}$, com diferentes sementes, utilizando $\hat{b} = 2$ (aproximadamente o valor estimado para a Lei de Gutenberg-Richter, dado por 2.009878) e a função `simular_catalogo_etas`. Para cada uma das $b = 1, \ldots, 100$ amostras o valor de $\hat{\theta}^{(b)}$ foi extraído, juntamente com o $\hat{\mu}(x, y)^{(b)}$. Todas convergiram após 11 a 18 iterações, sem nenhuma falha.

Os valores dos erro-padrão e viés *bootstrap* são dados por:

```
##                A       alpha          c          p           D          q      gamma
## Est    0.22846076  1.94867209 0.16027401 1.28172658 0.018228922 2.11616976 0.04525585
## EP     0.01056886  0.09329789 0.02257890 0.01253781 0.002298591 0.07580962 0.15432858
## EPB    0.02172104  0.26890268 0.07639258 0.03969417 0.006976795 0.25871173 0.29088490
## ViésB -0.02084282 -0.02381726 0.12157495 0.15556951 0.002124040 0.11351159 0.13643373
```

As duas primeiras linhas são os valores estimados pelo modelo e seu erro-padrão usual (calculado via hessiana). Podemos ver que para todos os parâmetros, o erro-padrão *bootstrap* é maior do que o usual. Os intervalos de confiança *bootstrap* serão:

```
##               A    alpha         c        p          D        q        gamma
## 2.5%  0.1707297 1.313721 0.1715007 1.366028 0.01065099 1.839206 0.0000000001
## 97.5% 0.2506438 2.375211 0.4393014 1.512546 0.03665571 2.844442 0.9022696682
```

Para γ ocorre um problema em que muitas simulações geraram valores de terremotos muito próximos do limiar ($m_0 = 4.5$), de modo que o modelo não detecta influência das magnitudes no aumento de dispersão espacial dos *aftershocks*. Assim, o quantil 2.5% desse parâmetro captura o limiar do espaço paramétrico do `optim` (definido em 10^{-10}).

Predição

Para a predição de eventos futuros (algo complicado de ser feito, como explicitado em Veen and Schoenberg (2008), Ogata (1988) e Ogata (1998), por exemplo), podemos usar uma metodologia baseada na simulação de catálogos futuros, condicional ao histórico dado pelo catálogo real, ao *background rate* estimado e ao conjunto de parâmetros obtidos pelo modelo.

Com esse método, é gerado um catálogo "expandido", com os eventos já ocorridos e novos que ocorrem após o tempo final T. Geram-se várias simulações, cada uma gerando uma possível realização do futuro, e agrega-se os valores temporal/espacialmente, para serem feitas predições do tipo: quantos eventos ocorrerão em $[T, T + \Delta t]$, e onde os mesmos possuem maiores chances de ocorrência.

Foi implementada uma função chamada `simular_previsao_etas` que realiza esse processo utilizando o catálogo passado, $\hat{\mu}(x, y), \hat{\theta}$ e um valor de horizonte (quantos dias serão simulados após o tempo final T). Outra função foi implementada, chamada `gerar_previsoes_etas`, recebendo os mesmos objetos e usando `simular_previsao_etas` internamente. O valor de $\hat{\theta}$ usado pode ser um único vetor (para a estimativa pontual, por exemplo), ou uma lista de vetores (para as réplicas *bootstrap*, por exemplo), que é sorteada em cada simulação. Dessa forma, é possível propagar a incerteza da estimação de $\hat{\theta}$ na predição, aproveitando os valores obtidos no estudo de simulação.

As predições (temporais e espaciais) são posteriormente agregadas usando as funções `agregar_previsao_temporal` e `agregar_previsao_espacial`, que extraem as informações de cada uma das simulações e retornam estatísticas como:

- Quantidade média de eventos por período de tempo (deixei 30 dias por padrão, para predição a nível de meses), bem como mediana e percentis (2.5% e 97.5%);
- Contagem média de eventos por célula/*pixel* do *grid* de interesse, bem como a probabilidade de que ao menos um evento tenha ocorrido na célula (calculada de maneira empírica, usando que $P(N_{\text{celula}} \geq 1) = 1 - \exp(-\hat{\lambda}_{\text{celula}})$, com $\hat{\lambda}_{celula}$ sendo estimada como a contagem média na célula).

Usando um único θ

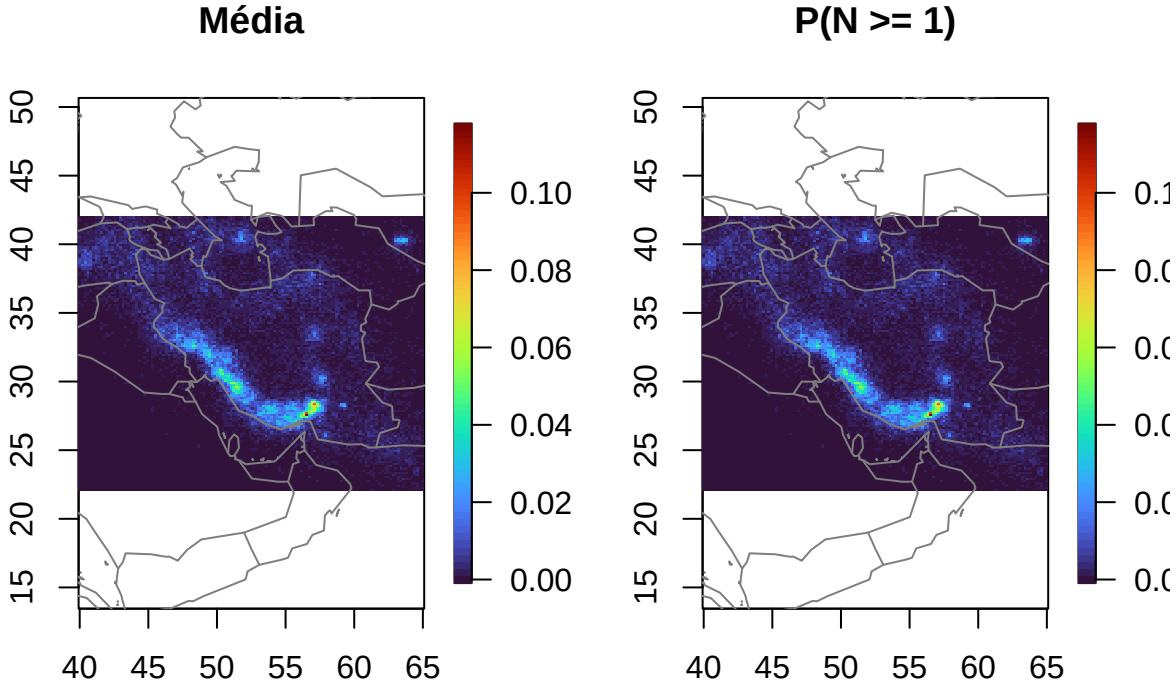
Para o catálogo de terremotos no Irã, simulei 1.000 predições após o tempo final, usando os valores de $\hat{\theta}$ (0.2284608, 1.9486721, 0.160274, 1.2817266, 0.0182289, 2.1161698, 0.0452558), em um horizonte de 210 dias (7 meses). Os valores temporais agregados para os 210 dias, mês a mês foram:

```
##   bin_inicio  bin_fim media mediana  p025 p975
## 1   13873.35 13903.35 4.808       4 0.000   13
## 2   13903.35 13933.35 5.060       5 1.000   13
```

```
## 3   13933.35 13963.35 4.954       4 1.000   12
## 4   13963.35 13993.35 5.077       5 1.000   12
## 5   13993.35 14023.35 5.093       5 0.975   12
## 6   14023.35 14053.35 5.008       4 1.000   12
## 7   14053.35 14083.35 5.095       5 1.000   12
```

Ou seja, a quantidade média esperada para cada mês é de aproximadamente 5 eventos/mês (o valor observado pelo catálogo completo é de aproximadamente 5.40 eventos/mês, com os últimos 12 meses tendo (2, 8, 5, 3, 3, 2, 3, 3, 3, 5, 0, 7, 1) eventos). Ou seja, a predição foi capaz de capturar o comportamento da quantidade de eventos ocorrendo em períodos de tempo futuros ao fim do período de observação.

Para a predição espacial, temos que o mapa da contagem média por célula e a probabilidade de ao menos um evento será:

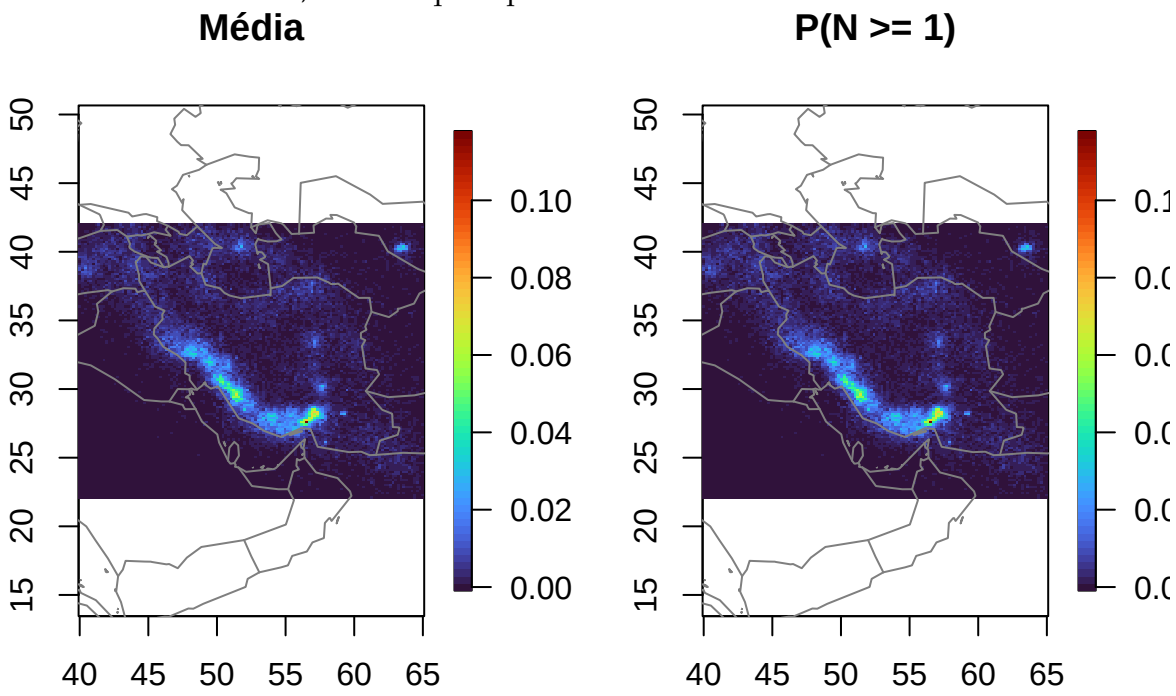


Usando os θ bootstrap

Quando usamos os valores de vários $\hat{\theta}^{(b)}$ estimados por meio de um *bootstrap*, aumentamos a incerteza presente na predição, mas os resultados são apresentados da mesma maneira. Teremos que a predição temporal será:

```
##   bin_inicio  bin_fim media mediana p025 p975
## 1   13873.35 13903.35 4.706       4    1   13
## 2   13903.35 13933.35 4.981       4    0   12
## 3   13933.35 13963.35 4.800       4    0   12
## 4   13963.35 13993.35 4.892       4    0   12
## 5   13993.35 14023.35 5.052       5    1   13
## 6   14023.35 14053.35 4.889       4    0   12
## 7   14053.35 14083.35 4.925       4    0   13
```

Neste caso, o valor médio por mês é um pouco menor do que no caso anterior, provavelmente devido à quantidade de simulações em que $\hat{\theta}^{(b)}$ possui valores que diminuem a intensidade condicional. De maneira similar, teremos que espacialmente:



Sensibilidade

Um dos principais problemas apontados pelo autor, é que a função `etas` é extremamente sensível à escolha de chute inicial para os parâmetros. Para verificar se o mesmo ocorre com o método proposto, foi realizado um estudo de sensibilidade, variando o valor inicial de θ em cada iteração.

Os catálogos foram contruídos usando a função `simular_catalogo_etas`, com $\theta = (A = 0.5, \alpha = 1.5, c = 0.25, p = 1.5, D = 0.1, q = 2, \gamma = 0.1)$, considerando $m_0 = 4.5$ e $b = 1.5$, usando `set.seed(123)`. Dois cenários de tamanho de amostra foram explorados, primeiramente usando `T_max = 3650`, e posteriormente usando `T_max = 5000`, para verificar se o tamanho de catálogo influencia no resultado final.

Duas metodologias são usadas para variar os parâmetros: **OAT** e **LHS**. No primeiro método, todos os parâmetros são mantidos no valor verdadeiro (especificado anteriormente), e cada um é perturbado de maneira individual separadamente (por isso **OAT** - *One At Time*). Cada parâmetro varia entre $\frac{1}{4}$ do valor real até 2 vezes o valor real, ao longo de uma sequência igualmente espaçada com 10 valores (menos os parâmetros p e q que precisam ser maiores do que 1, de modo que seus valores são determinados por $\theta_{variavel} = 1 + (\theta_{verdadeiro} - 1) \times$ multiplicador). Assim, são criados 70 pontos de partida distintos, cada um variando apenas um parâmetro dentre os 7 possíveis.

Porém, não é usual que todos os parâmetros sejam conhecidos a menos de um deles. Para isso um segundo método foi implementado, em que os valores de todos os parâmetros são perturbados conjuntamente usando amostragem por hipercubo latino (**LHS** - *Latin Hypercube Sampling*), que funciona da seguinte forma: para n pontos de partida em k parâmetros, cada uma das k dimensões é dividida em n faixas e cada uma é usada exatamente uma vez, garantindo cobertura equilibrada do espaço paramétrico multidimensional com menos pontos do que um fatorial completo. Aqui, foram utilizadas 50 pontos de partida distintos.

Para fins de visualização, as primeiras e as últimas entradas da matriz de *design* dos pontos iniciais é dada por:

```
##               A     alpha          c        p          D        q      gamma
##  [1,] 0.1250000 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [2,] 0.2222222 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [3,] 0.3194444 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [4,] 0.4166667 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [5,] 0.5138889 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [6,] 0.6111111 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [7,] 0.7083333 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [8,] 0.8055556 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
##  [9,] 0.9027778 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
## [10,] 1.0000000 1.5000000 0.25000000 1.500000 0.10000000 2.000000 0.10000000
## [11,] 0.6904647 3.0223080 0.07871798 1.338943 0.17249901 3.263291 0.04664732
## [12,] 0.3847757 1.3549030 0.28263245 1.233542 0.07745238 1.716240 0.07775635
## [13,] 0.1514160 1.0519954 0.31828567 1.492741 0.10117601 4.031965 0.22253082
## [14,] 0.8174373 0.4936352 0.11190258 2.019102 0.12204129 4.919364 0.07256729
## [15,] 1.2033701 4.7613038 0.30294915 1.162736 0.14133057 1.278643 0.14781675
## [16,] 0.9378407 0.9911100 0.93603471 2.045750 0.11664497 2.547733 0.30019096
## [17,] 0.7028772 4.5150162 0.47682866 1.151835 0.21917077 4.781158 0.02820848
## [18,] 1.9895430 2.2008551 0.13038995 1.211918 0.19582538 4.285333 0.24764748
## [19,] 0.8814421 1.5135764 0.66672297 2.715024 0.03073185 1.464841 0.10944940
## [20,] 0.1760598 0.4074005 0.19105242 1.270562 0.20691142 2.253528 0.10165796
```

Note que nas primeiras 10 linhas, todos os parâmetros são fixos, e muda-se apenas o valor de A, enquanto que nas 10 últimas, todos os parâmetros variam conjuntamente.

Resultados para `T_max = 3650`

Primeiramente, considerando um catálogo de 10 anos (3.650 dias), vejamos os valores sumarizados de cada uma das colunas, sua amplitude e desvios-padrão associados, para os 70 valores amostrados via **OAT**:

```
## [1] "Sumário:"
```

```
##                  A    alpha         c        p         D        q     gamma
## Min.    0.4716051 1.560100 0.3694916 1.673278 0.1511463 2.400953 0.1551788
## 1st Qu. 0.4716347 1.560223 0.3696242 1.673423 0.1513630 2.401914 0.1560600
## Median  0.4716519 1.560273 0.3697716 1.673700 0.1514276 2.402597 0.1562351
## Mean    0.4716511 1.560268 0.3697607 1.673617 0.1514109 2.402400 0.1562806
## 3rd Qu. 0.4716727 1.560304 0.3698830 1.673787 0.1514603 2.402750 0.1564843
## Max.    0.4717092 1.560468 0.3702657 1.674062 0.1515776 2.403382 0.1577166
```

```
## [1] "Amplitude:"
```

```
##            A        alpha            c            p            D            q        gamma
## 0.0001041406 0.0003682838 0.0007741232 0.0007840945 0.0004312994 0.0024286965 0.0025377542
```

```
## [1] "Desvios-Padrão:"
```

```
##            A        alpha            c            p            D            q        gamma
## 2.325216e-05 6.816715e-05 1.547667e-04 1.993249e-04 8.035295e-05 5.315653e-04 4.364740e-04
```

E para os 50 valores amostrados via **LHS**:

```
## [1] "Sumário:"
```

```
##                  A    alpha         c        p         D        q     gamma
## Min.    0.4715612 1.559883 0.3694882 1.673276 0.1508821 2.400061 0.1533677
## 1st Qu. 0.4716149 1.560172 0.3696382 1.673432 0.1512635 2.401404 0.1556857
## Median  0.4716520 1.560320 0.3697081 1.673571 0.1513572 2.401902 0.1565674
## Mean    0.4716475 1.560330 0.3697447 1.673584 0.1513434 2.401939 0.1567074
## 3rd Qu. 0.4716750 1.560421 0.3698791 1.673729 0.1514373 2.402555 0.1573568
## Max.    0.4717313 1.560877 0.3700670 1.674014 0.1516279 2.403415 0.1606347
```

```
## [1] "Amplitude:"
```

```
##            A        alpha            c            p            D            q        gamma
## 0.0001700673 0.0009940144 0.0005787770 0.0007381550 0.0007457352 0.0033535276 0.0072670730
```

```
## [1] "Desvios-Padrão:"
```

```
##            A        alpha            c            p            D            q        gamma
## 4.557061e-05 2.221641e-04 1.700534e-04 1.956113e-04 1.598672e-04 7.774207e-04 1.580219e-03
```

Podemos notar que, essencialmente, todos os valores iniciais resultaram em valores finais extremamente semelhantes, com uma variabilidade muito baixa, em ambos os métodos de amostragem. Assim, podemos constatar que o método proposto não é sensível à escolha de parâmetros iniciais. Além disso, é possível verificar o quanto cada parâmetro foi estimado de maneira errônea, por meio do erro relativo médio (dado por $\frac{\theta_{est} - \theta_{ver}}{\theta_{ver}}$) de cada parâmetro:

```
## [1] "Erro relativo médio:"
```

```
##           A       alpha           c           p           D           q       gamma
## -0.05670080  0.04019594  0.47901610  0.11573554  0.51382755  0.20110385  0.56458412
```

Podemos verificar também, além disso, o erro quadrático médio de cada um dos parâmetros:

```
## [1] "Erro quadrático médio:"
```

```
##            A        alpha            c            p            D            q        gamma
## 0.0008037463 0.0036353794 0.0143410519 0.0301381476 0.0026402027 0.1617714962 0.0031887257
```

Apesar do erro quadrático médio baixo, o erro relativo médio mostra que alguns parâmetros sofrem desvios significativos de suas estimativas verdadeiras (notadamente c, D e γ, com desvios próximos a 50% do valor original).

Resultados para `T_max = 5000`

Vejamos se o aumento no tamanho do catálogo tem influência nos resultados da sensibilidade. Primeiramente, para os 70 valores amostrados via **OAT**:

```
## [1] "Sumário:"
```

```
##                 A    alpha         c        p         D        q     gamma
## Min.    0.4479013 1.628697 0.3232357 1.642685 0.1014786 2.063349 0.1764024
## 1st Qu. 0.4479337 1.629242 0.3234649 1.642937 0.1015184 2.063562 0.1786717
## Median  0.4479937 1.629410 0.3236840 1.643199 0.1015350 2.063808 0.1792202
## Mean    0.4479966 1.629394 0.3236229 1.643135 0.1015351 2.063775 0.1791812
## 3rd Qu. 0.4480542 1.629566 0.3237436 1.643275 0.1015467 2.063969 0.1796909
## Max.    0.4481974 1.629784 0.3238522 1.643488 0.1016841 2.064161 0.1803243
```

```
## [1] "Amplitude:"
```

```
##            A        alpha            c            p            D            q        gamma
## 0.0002960957 0.0010876146 0.0006165452 0.0008029045 0.0002054359 0.0008119545 0.0039218535
```

```
## [1] "Desvios-Padrão:"
```

```
##            A        alpha            c            p            D            q        gamma
## 6.562349e-05 1.963373e-04 1.559092e-04 2.063120e-04 2.760782e-05 2.340688e-04 6.731426e-04
```

E para os 50 valores amostrados via **LHS**:

```
## [1] "Sumário:"
```

```
##                 A    alpha         c        p         D        q     gamma
## Min.    0.4478161 1.628077 0.3232724 1.642562 0.1013986 2.063230 0.1737633
## 1st Qu. 0.4479492 1.629165 0.3233820 1.642833 0.1014995 2.063461 0.1787189
## Median  0.4480149 1.629357 0.3234859 1.642949 0.1015189 2.063670 0.1790238
## Mean    0.4480196 1.629316 0.3234941 1.642972 0.1015432 2.063680 0.1788397
## 3rd Qu. 0.4480579 1.629514 0.3235890 1.643089 0.1015715 2.063868 0.1796620
## Max.    0.4483340 1.630199 0.3238772 1.643427 0.1018351 2.064131 0.1813168
```

```
## [1] "Amplitude:"
```

```
##            A        alpha            c            p            D            q        gamma
## 0.0005179637 0.0021222732 0.0006047792 0.0008644889 0.0004365495 0.0009010508 0.0075534393
```

```
## [1] "Desvios-Padrão:"
```

```
##            A        alpha            c            p            D            q        gamma
## 1.109267e-04 4.308769e-04 1.472093e-04 1.866259e-04 9.621445e-05 2.391969e-04 1.617971e-03
```

Aqui, temos o comportamento semelhante aos resultados obtidos com um catálogo de 10 anos, de alta consistência na estimação de todos os parâmetros, não sendo sensível à escolha do chute inicial. Vejamos porém, seu comportamento em relação aos erros de estimação:

```
## [1] "Erro relativo médio:"

##           A       alpha           c           p           D           q       gamma
## -0.10398760  0.08624100  0.29427693  0.09537783  0.01538464  0.03186761  0.79038922

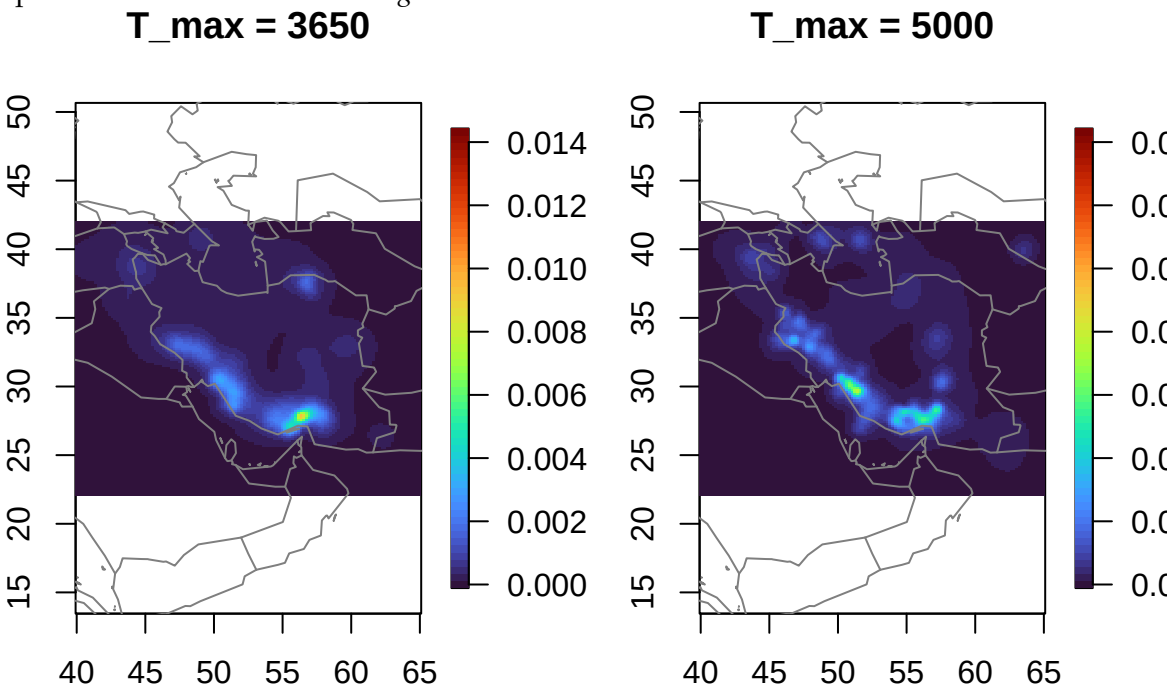
## [1] "Erro quadrático médio:"

##             A        alpha            c            p            D            q        gamma
## 2.703363e-03 1.673450e-02 5.412459e-03 2.046814e-02 2.371107e-06 4.062235e-03 6.248509e-03
```

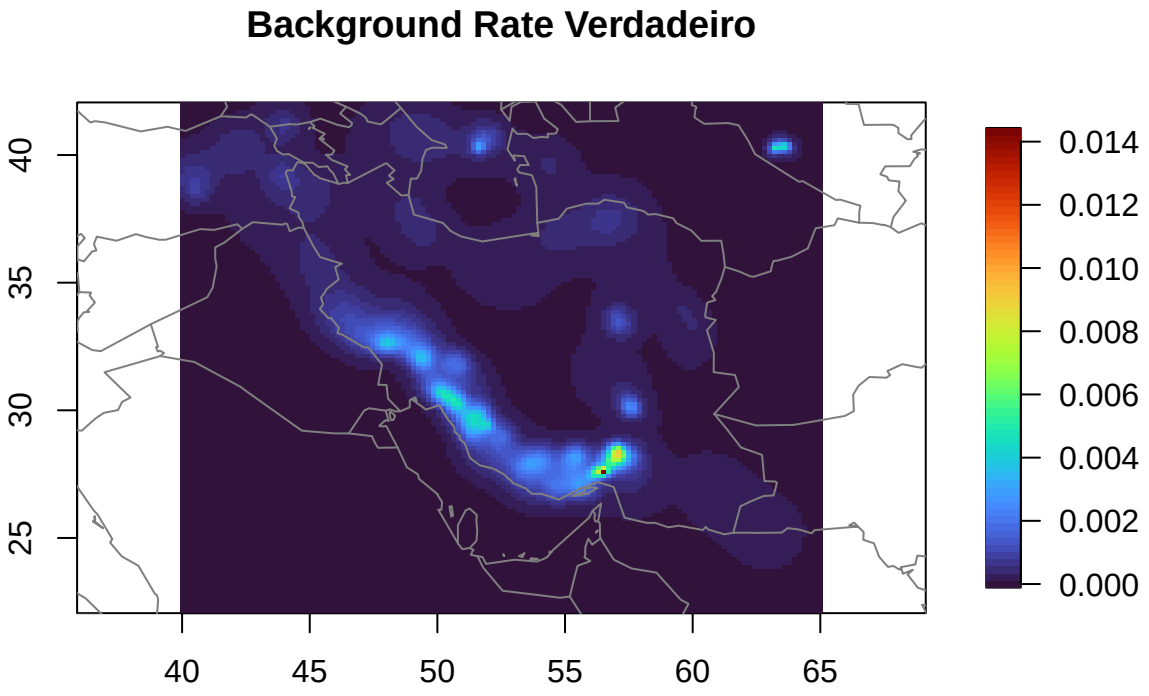
É possível perceber que os erros relativos de A e α mantiveram-se pequenos, os de c e p diminuíram consideravelmente e que os de D e q reduziram drasticamente. O único que aumentou significativamente o erro relativo foi γ, com quase 80% de erro relativo. Porém, esses parâmetros (D, q e γ) são altamente correlacionados, e a estimação conjunta de todos é complicada. A nível de comparação, vejamos-os conjuntamente:

```
##                 A alpha     c     p     D     q gamma
## T = 3650 -0.057 0.040 0.479 0.116 0.514 0.201 0.565
## T = 5000 -0.104 0.086 0.294 0.095 0.015 0.032 0.790
```

Dito isso, o ajuste foi extremamente satisfatório, e mostrou-se consistente independentemente do tamanho amostral, com melhora no erro conforme o tamanho do catálogo aumenta. Podemos comprovar isso observando o *background rate* médio estimado em cada caso:



Quando comparamos com o *background rate* verdadeiro usado para a simulação, que é:



Vemos que o *background rate* médio do catálogo maior é mais semelhante ao real, o que pode justificar o menor erro nos estimadores.

References

Jalilian, Abdollah. 2019. "**ETAS** : An *R* Package for Fitting the Space-Time ETAS Model to Earthquake Data." *Journal of Statistical Software* 88(Code Snippet 1).
URL: *http://www.jstatsoft.org/v88/c01/*

Louis, Thomas A. 1982. "Finding the Observed Information Matrix When Using the *EM* Algorithm." *Journal of the Royal Statistical Society Series B: Statistical Methodology* 44(2):226–233.
URL: *https://academic.oup.com/jrsssb/article/44/2/226/7027638*

Ogata, Yosihiko. 1988. "Statistical Models for Earthquake Occurrences and Residual Analysis for Point Processes." *Journal of the American Statistical Association* 83(401):9–27.
URL: *http://www.tandfonline.com/doi/abs/10.1080/01621459.1988.10478560*

Ogata, Yosihiko. 1998. "Space-Time Point-Process Models for Earthquake Occurrences." *Annals of the Institute of Statistical Mathematics* 50(2):379–402.
URL: *https://link.springer.com/10.1023/A:1003403601725*

Veen, Alejandro and Frederic P Schoenberg. 2008. "Estimation of Space–Time Branching Process Models in Seismology Using an EM–Type Algorithm." *Journal of the American Statistical Association* 103(482):614–624.
URL: *https://www.tandfonline.com/doi/full/10.1198/016214508000000148*