

# Notas de Aula - Capítulo 2

## Probabilidade

Caio Gomes Alves

24/03/2025

## 1 Variáveis Aleatórias

### 1.1 Variáveis aleatórias e funções de distribuição

**Example 1.1.** Considere um experimento em que uma moeda é lançada duas vezes. Seja  $X$  = total de caras nos dois lançamentos. Denotemos o evento cara como  $H$  e coroa como  $T$ . Logo:

Espaço Amostral ( $\Omega$ )	$X$
HT	1
TH	1
HH	2
TT	0

Logo,  $X : \mathcal{F} \rightarrow \mathbb{R}$ . Vale também que,  $\forall x$  valor na imagem de  $X$ ,  $X^{-1}(x) \in \mathcal{F}$ . Por exemplo:

$$x = 1 \Rightarrow X^{-1}(1) = \{HT, TH\}$$

$$x = 2 \Rightarrow X^{-1}(2) = \{HH\}$$

$$x = 0 \Rightarrow X^{-1}(0) = \{TT\}$$

**Definition 1.1** (Variável aleatória). Seja  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidades. Uma função  $X : \mathcal{F} \rightarrow \mathbb{R}$  é variável aleatória se  $[x \in I] \in \mathcal{F}$ ,  $I \in \mathbb{R}$  (ou, equivalentemente, se  $\{\omega : X(\omega) \in I\} \in \mathcal{F}$ ;  $X^{-1}(I) \in \mathcal{F}$ ).

**Definition 1.2** (Distribuição Acumulada). Considere um espaço de probabilidades  $(\Omega, \mathcal{F}, P)$  e  $X : \mathcal{F} \rightarrow \mathbb{R}$  uma variável aleatória, defina  $F(r) = P(X \leq r) = P(\{\omega : X(\omega) \leq r\})$ .

**Example 1.2.** Seja  $X$  = número de caras em dois lançamentos de moeda (honesta). Temos que as probabilidades de  $X$  são dadas por:

$$P(X = 0) = P(\{TT\}) = \frac{1}{4}$$

$$P(X = 1) = P(\{TH, HT\}) = \frac{2}{4}$$

$$P(X = 2) = P(\{HH\}) = \frac{1}{4}$$

Para encontrarmos a função de distribuição acumulada, podemos particinar o espaço e “acumular” as probabilidades. Para  $r < 0$ :

$$F(r) = P([X \leq r]) = P(\emptyset) = 0$$

Para  $r \in [0, 1)$ :

$$F(r) = P([X \leq r]) = P(X \leq 0) = \frac{1}{4}$$

Para  $r \in [1, 2)$ :

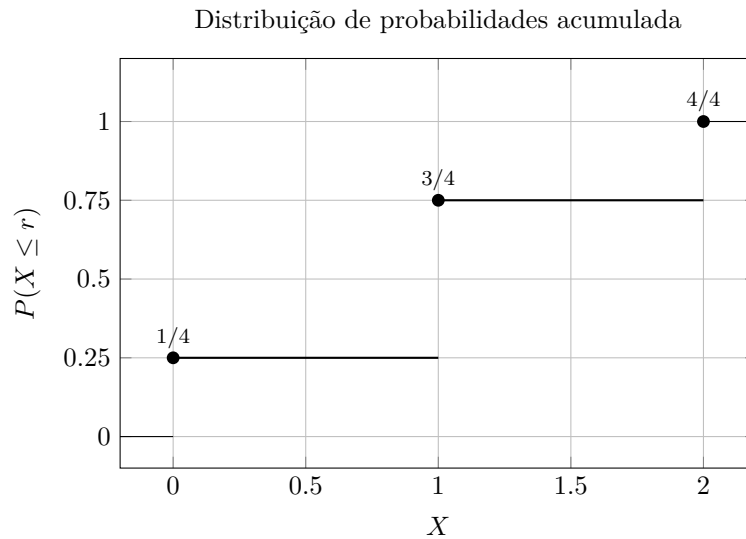
$$F(r) = P([X \leq r]) = P(X \leq 1) = P(X = 0) + P(X = 1) = \frac{3}{4}$$

Para  $r \geq 2$ :

$$F(r) = P([X \leq r]) = P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2) = 1$$

Logo,  $F$  é dada por:

$$F(r) = \begin{cases} 0, & r < 0 \\ \frac{1}{4}, & r \in [0, 1) \\ \frac{3}{4}, & r \in [1, 2) \\ 1, & r \geq 2 \end{cases}$$



**Theorem 1.1** (Propriedades da distribuição acumulada). *Seja  $X$  uma variável aleatória definida em  $(\Omega, \mathcal{F}, P)$ , então a f.d.a. de  $X$  ( $F_X$  ou  $F$ ) verifica:*

- a)  $F$  é monótona não decrescente;
- b)  $F$  é contínua à direita;
- c)  $\lim_{t \rightarrow -\infty} F(t) = 0$  e  $\lim_{t \rightarrow \infty} F(t) = 1$ .

*Proof.*

- a) Dados  $a, b \in \mathbb{R} : a \leq b$ ;  $[X \leq a] \subseteq [X \leq b] \Rightarrow P([X \leq a]) \leq P([X \leq b]) \Rightarrow F(a) \leq F(b)$ .
- b) Se  $X_n \downarrow x$ , quando  $n \rightarrow \infty$ , temos que  $\{[X \leq x_n]\}_{n \geq 1}$  é tal que  $\bigcap_{n \geq 1} [X \leq x_n] = [X \leq x]$ . Isso significa que  $[X \leq x]$  acontece se e somente se  $[X \leq x_n] \forall n$ . Além disso,  $[X \leq x_n] \downarrow [X \leq x]$  quando  $n \rightarrow \infty$ , logo, pela continuidade da função de probabilidade  $P([X \leq x_n]) \downarrow P([X \leq x]), n \rightarrow \infty$ .
- c) Considere agora que  $x_n \downarrow -\infty \Rightarrow [X \leq x_n] \downarrow \emptyset$ ,  $n \rightarrow \infty \Rightarrow F(x_n) = P([X \leq x_n]) \downarrow P(\emptyset) = 0$ ,  $n \rightarrow \infty$ . Se  $x_n \uparrow \infty \Rightarrow [X \leq x_n] \uparrow \Omega$ ,  $n \rightarrow \infty \Rightarrow F(x_n) = P([X \leq x_n]) \uparrow P(\Omega) = 1$ ,  $n \rightarrow \infty$ .

□

**Theorem 1.2.** Se  $F$  é a f.d.a. da variável aleatória  $X$ , então:

- a) Existem e são finitos os limites laterais  $\lim_{t \rightarrow r^-} F(t), \lim_{t \rightarrow r^+} F(t), \forall r \in \mathbb{R}$  e  $\lim_{t \rightarrow r^-} F(t) \leq \lim_{t \rightarrow r^+} F(t)$ ;
- b)  $\lim_{t \rightarrow r^+} F(t) = F(r), \forall r \in \mathbb{R}$ ;
- c)  $F$  é descontínua em  $r, r \in \mathbb{R}$  se e somente se  $\lim_{t \rightarrow r^-} F(t) < F(r)$ , com um salto de tamanho  $F(r) - \lim_{t \rightarrow r^-} F(t)$ ;
- d)  $\forall r \in \mathbb{R}, P(X = r) = F(r) - \lim_{t \rightarrow r^-} F(t)$ ;
- e) Existem no máximo um total enumerável de descontinuidades em  $F$ .

*Proof.*

- a)  $F$  é monótona e limitada ( $0 \leq F \leq 1$ ). Logo, os limites laterais existem e são limitados.
- b) Como  $F$  é monótona não-decrescente,  $\forall x, y : x \leq y \Rightarrow F(x) \leq F(y)$ . Logo  $\lim_{t \rightarrow r^-} F(t) \leq \lim_{t \rightarrow r^+} F(t)$ .
- c) Como  $F$  é monótona não-decrescente, uma descontinuidade só ocorre se e somente se  $\lim_{t \rightarrow r^-} F(t) < \lim_{t \rightarrow r^+} F(t) = F(r)$ .
- d) Seja  $r \in \mathbb{R}$ .  $[X \leq r] = \bigcap_{n=1}^{\infty} (r - \frac{1}{n} < x \leq r)$ , logo:

$$\begin{aligned}
 P([X = r]) &= P\left(\bigcap_{n=1}^{\infty} \left(r - \frac{1}{n} < x \leq r\right)\right) \\
 &\Downarrow (\text{Teorema da continuidade}) \\
 &= \lim_{n \rightarrow \infty} P\left(\left(r - \frac{1}{n} < x \leq r\right)\right) \\
 &= \lim_{n \rightarrow \infty} \left(F(r) - F\left(r - \frac{1}{n}\right)\right) \\
 &= F(r) - \lim_{n \rightarrow \infty} F\left(r - \frac{1}{n}\right) \\
 P([X = r]) &= F(r) - \lim_{t \rightarrow r^-} F(t)
 \end{aligned}$$

- e) Seja  $\mathcal{D}$  o conjunto de pontos de descontinuidades de  $F$ , e seja  $\lim_{t \rightarrow x^-} F(t) = F(x^-)$ . Logo:

$$\mathcal{D} = \{x \in \mathbb{R} : F(x) - F(x^-) > 0\}$$

Seja  $\mathcal{D}_n$  o conjunto de pontos para os quais a amplitude do salto é maior ou igual a  $\frac{1}{n}$ . Logo:

$$\mathcal{D}_n = \left\{x \in \mathbb{R} : F(x) - F(x^-) \geq \frac{1}{n}\right\} \Rightarrow \#D = |D| \leq n$$

Se  $x \in \mathcal{D} \Rightarrow \exists n_0 > 1 : F(x) - F(x^-) \geq \frac{1}{n_0} \Rightarrow x \in \bigcup_{n=1}^{\infty} \mathcal{D}_n$ . Se  $x \in \bigcup_{n=1}^{\infty} \mathcal{D}_n \Rightarrow \exists n_1 : x \in \mathcal{D}_{n_1} \Rightarrow x \in \mathcal{D}$ .  $\mathcal{D}$  portanto é a união enumerável de conjuntos finitos, logo é enumerável.

□

## 1.2 Natureza das variáveis aleatórias

- $X$  é uma variável aleatória discreta se os valores que ela toma pertencem a um conjunto enumerável, logo  $X : \Omega \rightarrow \{x_1, x_2, \dots\}$  (ou seja,  $X(\omega) \in \{x_1, x_2, \dots\}, \forall \omega \in \Omega$ ) e  $P : \{x_1, x_2, \dots\} \rightarrow [0, 1]$  é dado por  $P(x_i) = P\{\omega : \omega \in \Omega \text{ e } X(\omega) = x_i\} \forall i \geq 1$ .
- $X$  é uma variável aleatória absolutamente contínua se  $\exists f$  (uma função) tal que  $f(x) \geq 0, \forall x \in \mathbb{R}$  e  $F_X(x) = \int_{-\infty}^x f(t)dt$  (onde  $f$  é chamada de densidade de  $X$ ).

Sob **(a)** temos que  $[X \leq x] = \bigcup_{i: x_i \leq x} [X = x_i]$ . Logo  $F_X(x) = \sum_{i: x_i \leq x} P(x_i)$ .

Sob **(b)** estamos afirmando que  $F_X$  é a integral de  $f$  (ou seja,  $f$  é a sua derivada) para todo  $x$  exceto em um conjunto de medida de Lebesgue nula, ou seja, se seu comprimento for zero ( $\int_a^a f(t)dt = 0$ ). Ainda sob **(b)**, se  $f$  é uma função de densidade podemos definir  $F(x) = \int_{-\infty}^x f(t)dt$  e  $F$  verifica:


- $x \leq y \Rightarrow F(x) \leq F(y)$ ;
- Se  $x_n \downarrow x \Rightarrow F(x_n) \downarrow F(x)$ ;
- Se  $x_n \downarrow -\infty \Rightarrow F(x_n) \downarrow 0$  e se  $x_n \uparrow \infty \Rightarrow F(x_n) \uparrow 1$ .

Dada uma variável aleatória com distribuição  $F_X$ ,  $X$  tem densidade se:

- $F_X$  é contínua;
- $F_X$  é derivável por partes (ou derivável no interior de um número finito ou enumerável de intervalos fechados cuja união é igual a  $\mathbb{R}$ ), ou derivável para todo  $x$  exceto um número finito (enumerável) de pontos.

**Example 1.3.**

$$F_X(x) = \begin{cases} 0, & x < 0 \\ x, & x \in [0, 1] \\ 1, & x > 1 \end{cases}$$




Notas:

- $F_X$  é contínua;
- $\{0, 1\}$  são pontos sem derivada;
- Podemos definir os seguintes intervalos em que  $F_X$  é derivável:  $(-\infty, 0), (0, 1), (1, \infty)$ ;
- $F'_X(x) = \begin{cases} 1, & x \in (0, 1) = f_X(x); \\ 0, & c.c. \end{cases}$ ;
- $f(0)$  e  $f(1)$  podem ser definidos como zero ou um, já que tais definições não alteram  $F_X(x) = \int_{-\infty}^x f(t)dt$ .

Em contrapartida, considere:

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$




Notas:

- $F_X$  não é contínua;
- $P(X = 0) = \lim_{x \rightarrow 0^+} F_X(x) - \lim_{x \rightarrow 0^-} F_X(x) = 1$ .

**Example 1.4.** Considere a densidade triangular:

$$f_X(x) = \begin{cases} x, & \text{se } 0 \leq x < 1 \\ 2 - x, & \text{se } 1 \leq x < 2 \\ 0 & c.c. \end{cases}$$



Por definição,  $f(x) \geq 0 \forall x$ . Para verificarmos que a probabilidade total é igual a um, podemos realizar a seguinte integração por partes:

$$\begin{aligned}
\int_{-\infty}^x f_X(x)dx &= \int_0^2 f_X(x)dx \\
&= \int_0^1 xdx + \int_1^2 (2-x)dx \\
&= \frac{x^2}{2} \Big|_0^1 + 2x \Big|_1^2 - \frac{x^2}{2} \Big|_1^2 \\
&= 1
\end{aligned}$$

O que demonstra que  $f_X(x)$  é densidade de probabilidade.

**Conjecture 1.1.** *Cada função de distribuição se corresponde com apenas uma distribuição? Não.*

*Proof.* Considere, por exemplo, que a variável aleatória  $X \sim N(0,1)$ . Logo, a sua função distribuição de probabilidade é dada por  $f_X(x) = \frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$  e  $\Phi(x)$  é sua acumulada. Vejamos que  $X \sim N(0,1) \iff -X \sim N(0,1)$ :

Seja  $\omega$  um possível valor de  $-X$ , devemos calcular  $P(-X \leq \omega)$  e provar que  $P(-X \leq \omega) = \Phi(\omega)$ :

$$P(-X \leq \omega) = P(X \geq -\omega) = 1 - P(X \leq \omega) = 1 - \Phi(-\omega) = 1 - (1 - \Phi(\omega)) = \Phi(\omega)$$

□

### 1.3 Variáveis aleatórias e $\sigma$ -álgebra de Borel

Se  $X$  é uma variável aleatória em  $(\Omega, \mathcal{A}, P)$ , cada evento  $[X \leq x] \in \mathcal{A} \forall x \in \mathbb{R}$ . Isto é,  $[X \in \mathcal{B}]$ , onde  $[X \in \mathcal{B}] = [X \leq x]$  é um evento e  $P(X \in \mathcal{B})$  é bem definido. No entanto, a operacionalidade do sistema  $(\Omega, \mathcal{A}, P)$  pode ser estendido a todo boreliano (ou seja, a todos os elementos da  $\sigma$ -álgebra de Borel, que é a menor  $\sigma$ -álgebra contendo os intervalos cujos comprimentos estejam bem definidos).

**Proposition 1.1.** *Se  $X$  é uma variável aleatória em  $(\Omega, \mathcal{A}, P)$ , então o evento  $[x \in \mathcal{B}] = \{\omega : \omega \in \Omega \text{ e } X(\omega) \in \mathcal{B}\}$  é um evento aleatório para todo  $\mathcal{B}$  boreliano (ou seja,  $[x \in B] \in \mathcal{A} \forall B \in \mathcal{B}$ ).*

Podemos ver que diferentes tipos de intervalos (leia-se borelianos) podem ser mostrados como pertencentes à  $\sigma$ -álgebra, de modo que variáveis aleatórias que operam sobre esses intervalos estarão bem definidas:

1. Se  $B = (-\infty, b] \Rightarrow [X \in B] \in \mathcal{A}$  de acordo com a definição de variável aleatória;
2. Se  $B = (a, \infty)$ , podemos fazer  $B = (-\infty, a]^c$ . Como o evento  $[X \leq a] \in \mathcal{A}$  por definição, sendo  $\mathcal{A}$  uma  $\sigma$ -álgebra, deve ocorrer que  $[X \leq a]^c = B \in \mathcal{A}$ , ou seja,  $B \in \mathcal{A}$ ;
3. Se  $B = (a, b] \Rightarrow [X \in B] = [X \in (a, b]] = [X \leq b] - [X \leq a]$ . Como  $[X \leq b] \in \mathcal{A}$  e  $[X \leq a] \in \mathcal{A}$ , então  $P(X \in B) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$ ;
4. Se  $B = (a, b) \Rightarrow B = \bigcup_{n=1}^{\infty} (a, b - \frac{1}{n}]$ . Sabemos que os eventos  $(a < X \leq b - \frac{1}{n}) \in \mathcal{A}$  e as suas uniões também pertencem à  $\mathcal{A}$ . Quanto à probabilidade, temos  $P(X \in B) = P(\bigcup_{n=1}^{\infty} (a < X \leq b - \frac{1}{n})) = \lim_{n \rightarrow \infty} P((a < X \leq b - \frac{1}{n})) = \lim_{n \rightarrow \infty} F_X(b - \frac{1}{n}) - F_X(a) = F_X(b^-) - F_X(a)$ ;
5. Se  $B = \bigcup_{i=1}^n B_i : B_i \in \mathcal{A} \forall i$ , e sendo os  $B_i$ 's disjuntos, temos que  $[X \in B] = \bigcup_{i=1}^n [X \in B_i] \Rightarrow P([X \in B]) = \sum_{i=1}^n P(X \in B_i)$ .

Podemos assim reformular os axiomas de Kolmogorov:

- $Ax_1(K)$ :  $P_X(B) = P(X \in B) \geq 0$ ;
- $Ax_2(K)$ :  $P_X(\mathbb{R}) = P(X \in \mathbb{R}) = 1$ ;

- $Ax_3(K)$ : Se  $B_1, \dots, B_n \in \mathcal{B}$ , com  $B_i \cap B_j = \emptyset \forall i \neq j \Rightarrow P_X(\bigcup B_n) = P(X \in \bigcup_n B_n) = P(\bigcup_n [X \in B_n]) = \sum_n P(X \in B_n)$ .

**Definition 1.3.** A probabilidade  $P_X$  definida na  $\sigma$ -álgebra de Borel por  $P_X(B) = P(X \in B)$  é a distribuição de  $X$ .

**Proposition 1.2.**

- a) Se  $X$  é uma variável aleatória discreta com valores em  $\{x_1, x_2, \dots\} \Rightarrow P_X(B) = \sum_{i: x_i \in B} P(x_i)$ ;
- b) Se  $X$  é absolutamente contínua com densidade  $f \Rightarrow P_X(B) = \int_B f_X dx$ .

## 1.4 Variáveis contínuas

**Proposition 1.3.** Se  $X \sim f_X$ ,  $y = bx + c$ ,  $b > 0$  e  $c \in \mathbb{R} \Rightarrow Y \sim f_Y$  onde  $f_Y(y) = \frac{1}{b} f_X(\frac{y-c}{b})$ ;  $y \in \mathbb{R}$ , onde  $c$  é dito um parâmetro de posição (muitas vezes de posição central) e  $b$  um parâmetro de escala.

### 1.4.1 Exemplos

**Example 1.5** (Distribuição Normal).

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \Rightarrow f_{\mu, \sigma}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Aqui,  $\mu$  representa a média (posição central) da distribuição e  $\sigma^2$  a sua variância.

**Example 1.6** (Distribuição Cauchy).

$$f(x) = \frac{1}{\pi(1+x^2)} \Rightarrow f_{b,M}(x) = \frac{1}{b} \frac{1}{\pi \left(1 + \left(\frac{x-M}{b}\right)^2\right)} = \frac{b}{\pi(b^2 + (x-M)^2)}$$

Neste caso,  $M$  é a mediana da distribuição e  $b$  representa a distância entre  $M$  e o 1º quartil da distribuição.

**Example 1.7** (Distribuições Exponencial e Gamma). Considere  $g(x) = e^{-x} I_{0,\infty}(x)$ . Sabemos que  $g$  é uma distribuição de probabilidade pois:

$$\begin{cases} g(x) \geq 0 \forall x \in (0, \infty) \\ \int_0^\infty e^{-x} dx = 1 \end{cases}$$

Vamos agora incluir no formato do tipo exponencial um componente polinomial. Dado  $\alpha > 0$ , defina  $g(x) = x^{\alpha-1} e^{-x}$ . Podemos ver que  $g$  é integrável, de modo que:

$$\begin{aligned} \int_0^\infty g(x) dx &= \int_0^\infty x^{\alpha-1} e^{-x} dx = \Gamma(\alpha) \\ f_X(x) &= \begin{cases} \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x} & x > 0 \\ 0 & c.c. \end{cases} \end{aligned}$$

Defina agora  $y = \frac{X}{\beta}$  onde  $X \sim \text{Gamma}(\alpha, 1)$  e  $\beta > 0$ . A densidade de  $Y$  pode ser encontrada por meio de:

$$P(Y \leq y) = P\left(\frac{X}{\beta} \leq y\right) = P(X \leq \beta y) \Rightarrow F_Y(y) = F_X(\beta y)$$

$$f_Y(y) = \beta f_X(\beta y) = \beta \frac{(\beta y)^{\alpha-1}}{\Gamma(\alpha)} e^{-\beta y} = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$$

Nesse caso (conhecido como distribuição Gama)  $\frac{1}{\beta}$  é um parâmetro de escala e  $\alpha$  é um parâmetro de forma. Temos alguns casos especiais, como:

- Se  $\alpha = 1$  :  $Y \sim \text{Exp}(\beta)$ ;
- Se  $\alpha = \frac{n}{2}$ , com  $n$  inteiro e  $\beta = \frac{1}{2}$  :  $Y \sim \chi^2(n)$